

Le Machine Learning

Apprendre à partir des données : concepts, algorithmes et pièges de l'apprentissage automatique.

NIVEAU

Intermédiaire

DURÉE ESTIMÉE

3 h

CHAPITRES

4

OBJECTIFS PÉDAGOGIQUES

- Expliquer comment une machine apprend à partir de données.
- Distinguer classification et régression, et connaître les algorithmes de base.
- Comprendre le rôle des données d'entraînement et de test.
- Diagnostiquer le sur-apprentissage et connaître les moyens de le limiter.

Sommaire

1.	Le principe : apprendre des données	3
2.	Classification, régression et algorithmes de base	6
3.	Données d'entraînement, de test et validation	9
4.	Le sur-apprentissage et comment l'éviter	12
◆	Résumé visuel	15
Q.	Quiz d'évaluation	16
?	Foire aux questions (FAQ)	18
★	Conclusion	19

1

CHAPITRE 1

Le principe : apprendre des données

Le Machine Learning renverse la logique de la programmation classique. Ce chapitre explique ce renversement et pourquoi il change tout.


Explication détaillée

En programmation classique, un humain écrit des règles, la machine les applique à des données pour produire des résultats. En Machine Learning, on inverse : on fournit à la machine des données ET les résultats attendus, et c'est elle qui déduit les règles. Ces règles apprises constituent le « modèle ».

Concrètement, un algorithme d'apprentissage ajuste des paramètres internes pour réduire l'écart entre ses prédictions et les bonnes réponses connues. Cet écart s'appelle l'erreur, ou la « fonction de coût ». Apprendre, c'est minimiser cette erreur, un peu comme descendre une pente jusqu'au point le plus bas.

Une fois entraîné, le modèle est capable de généraliser : appliqué à des données nouvelles qu'il n'a jamais vues, il produit une prédiction. C'est là toute la valeur — et toute la difficulté — du Machine Learning : réussir non pas sur les exemples d'entraînement, mais sur des cas inédits.

Cette approche est pertinente quand les règles sont trop nombreuses ou trop subtiles pour être écrites à la main. Reconnaître un chat sur une photo, par exemple, est impossible à décrire par des règles explicites : on montre des milliers d'images, et le modèle apprend seul les motifs pertinents.



Le flux typique d'un projet de Machine Learning, de la collecte des données à la prédiction.

► EXEMPLE CONCRET — EDUMENTOR AI

Dans EduMentor AI, imaginons un modèle qui prédit si un apprenant risque d'abandonner un cours. Plutôt que d'écrire des règles, on lui fournit l'historique de nombreux apprenants (temps passé, scores, régularité) avec l'information « a abandonné / a terminé ». Le modèle apprend les motifs associés à l'abandon et peut alerter en amont.

► EXEMPLE CONCRET

Un exemple hors éducation : la prévision du prix de vente d'un logement. Plutôt que d'écrire des règles (« +10 % par chambre »), on fournit au modèle des milliers de ventes passées avec leurs caractéristiques (surface, quartier, étage) et leur prix. Le modèle apprend les relations et estime le prix d'un bien nouveau. C'est du Machine Learning appliqué à la régression.

À RETENIR

Le Machine Learning apprend les règles à partir d'exemples au lieu de les recevoir toutes faites. Apprendre = minimiser l'erreur entre prédictions et réponses connues.

ATTENTION

Un modèle n'apprend que ce que contiennent ses données. Des données incomplètes ou non représentatives produisent un modèle inutile, voire trompeur.

× ERREURS FRÉQUENTES

Se concentrer sur l'algorithme en négligeant les données. Un algorithme sophistiqué nourri de données médiocres donne un modèle médiocre : la qualité des données prime sur le choix du modèle.

★ ASTUCE

Consacrez au moins autant d'effort à comprendre et nettoyer vos données qu'à choisir votre modèle. Les praticiens expérimentés y passent souvent la majorité de leur temps.

CONSEILS

- Consacrez le plus gros de votre effort à la qualité des données : c'est le facteur numéro un de réussite.
- Définissez clairement ce que vous voulez prédire avant de choisir un algorithme.

QUESTIONS DE RÉFLEXION

- Pourquoi dit-on qu'un modèle ne peut apprendre que ce que contiennent ses données ? Quelles conséquences si un cas important est absent du jeu d'entraînement ?

RÉSUMÉ DU CHAPITRE

- La programmation classique applique des règles ; le ML les apprend.
- Apprendre revient à minimiser une erreur.
- L'objectif est de généraliser à des données nouvelles.

MINI-EXERCICE

Reformulez la différence entre programmation classique et Machine Learning en une phrase, à l'aide des mots « règles » et « données ».

Piste : En programmation classique, l'humain écrit les règles ; en Machine Learning, la machine déduit les règles à partir des données et des réponses attendues.

2

CHAPITRE 2

Classification, régression et algorithmes de base

L'apprentissage supervisé se décline en deux grandes tâches. Les distinguer, c'est déjà savoir quel type de modèle utiliser.

Explication détaillée

La classification prédit une catégorie parmi un ensemble fini : un e-mail est spam ou non, une image représente un chat, un chien ou un oiseau, un apprenant est débutant, intermédiaire ou avancé. La sortie est une étiquette discrète.

La régression prédit une valeur numérique continue : le prix d'un appartement, la température de demain, le temps qu'un apprenant mettra à terminer un module. La sortie est un nombre, pas une catégorie.

Plusieurs algorithmes classiques permettent d'aborder ces tâches. La régression linéaire modélise une relation par une droite. Les k plus proches voisins (k -NN) classent un point selon la majorité de ses voisins les plus proches. Les arbres de décision enchaînent des questions binaires. Chacun a ses forces : simplicité, interprétabilité, robustesse.

Le choix d'un algorithme dépend du problème, de la quantité de données, du besoin d'interprétabilité et des ressources disponibles. Il n'existe pas d'algorithme universellement meilleur : c'est le fameux principe du « no free lunch ».

COMPARAISON DE QUELQUES ALGORITHMES CLASSIQUES

Algorithme	Tâche	Force	Limite
Régression linéaire	Régression	Simple, interprétable	Ne capte que les relations linéaires
Régression logistique	Classification	Robuste, probabiliste	Frontières simples
k plus proches voisins	Classif./régression	Intuitif, sans entraînement	Lent à grande échelle
Arbre de décision	Classif./régression	Très interprétable	Sur-apprend facilement
Forêt aléatoire	Classif./régression	Performant, robuste	Moins interprétable

► EXEMPLE CONCRET — EDMENTOR AI

Le module de diagnostic d'EduMentor AI est une tâche de classification : à partir des réponses au quiz, il attribue une catégorie (débutant, intermédiaire, avancé). Si l'on cherchait plutôt à estimer le nombre d'heures nécessaires pour maîtriser un chapitre, on basculerait sur une tâche de régression.

► EXEMPLE CONCRET

Pour classer des e-mails en spam ou non-spam, on peut débuter avec une régression logistique : simple, rapide, et surtout interprétable (on voit quels mots pèsent le plus). Si la performance est insuffisante, on passe à une forêt aléatoire, plus puissante mais moins transparente. Ce cheminement du simple au complexe est une bonne pratique universelle.

À RETENIR

Classification = prédire une catégorie (sortie discrète). Régression = prédire une valeur numérique (sortie continue).

BONNES PRATIQUES

Commencez toujours par un modèle simple et interprétable (régression linéaire, arbre de décision) comme référence, avant de tester des modèles plus complexes.

◆ CONSEIL PROFESSIONNEL

Établissez toujours une « ligne de base » avec un modèle simple avant de tester des modèles complexes. Sans cette référence, vous ne saurez pas si la complexité ajoutée apporte réellement quelque chose.

CONSEILS

- Posez-vous la question : ma sortie est-elle une étiquette ou un nombre ? La réponse oriente vers classification ou régression.
- Privilégiez l'interprétabilité quand une décision doit être expliquée (santé, éducation, finance).

RÉSUMÉ DU CHAPITRE

- Deux tâches supervisées : classification et régression.
- Algorithmes de base : régression linéaire, k-NN, arbres de décision.
- Aucun algorithme n'est universellement supérieur.

MINI-EXERCICE

« Prédire la note finale sur 20 d'un étudiant » : classification ou régression ? Et « prédire s'il réussit ou échoue » ?

Piste : Prédire une note sur 20 est une régression (valeur continue) ; prédire réussite/échec est une classification (deux catégories).

EXERCICE

FACILE Pour prédire si un client va résilier son abonnement (oui/non), citez un algorithme adapté et indiquez s'il s'agit de classification ou de régression.

Piste : Classification (sortie oui/non). Une régression logistique ou un arbre de décision conviennent bien.

EXERCICE

AVANCÉ Vous hésitez entre un arbre de décision et une forêt aléatoire. Quel critère, autre que la performance brute, pourrait faire pencher pour l'arbre ?

Piste : L'interprétabilité : un arbre unique est facile à expliquer (suite de questions), ce qui est précieux quand une décision doit être justifiée. La forêt, plus performante, est moins transparente.

3

CHAPITRE 3

Données d'entraînement, de test et validation

Un modèle qui réussit sur ses exemples d'entraînement n'est pas forcément bon. Ce chapitre explique comment évaluer honnêtement un modèle.

Explication détaillée

On ne juge jamais un modèle sur les données qui ont servi à l'entraîner : il les a « vues » et pourrait les avoir mémorisées. On réserve donc une partie des données, le jeu de test, que le modèle ne voit jamais pendant l'apprentissage. La performance sur ce jeu de test estime la capacité de généralisation.

En pratique, on divise souvent les données en trois : un jeu d'entraînement (pour apprendre), un jeu de validation (pour régler les choix du modèle), et un jeu de test (pour l'évaluation finale, une seule fois). Cette séparation prévient l'auto-illusion.

Pour tirer le meilleur parti de données limitées, on utilise la validation croisée : on découpe les données en plusieurs blocs, on entraîne et on teste plusieurs fois en faisant tourner les blocs, puis on moyenne les résultats. L'estimation est plus robuste.

Le choix des métriques compte aussi. En classification, la précision globale peut tromper si les catégories sont déséquilibrées ; on complète avec la précision, le rappel et la matrice de confusion, qui montrent où le modèle se trompe.

Découpe typique d'un jeu de données



La séparation des données en entraînement, validation et test est la base d'une évaluation honnête.

► EXEMPLE CONCRET — EDUMENTOR AI

Pour évaluer un modèle d'EduMentor AI prédisant l'abandon, on n'utiliserait jamais les mêmes apprenants pour l'entraînement et l'évaluation. On garderait un groupe d'apprenants « jamais vus » pour mesurer si le modèle alerte correctement dans la vraie vie.

► EXEMPLE CONCRET

Dans un concours de science des données, les organisateurs gardent secret un jeu de test : les participants entraînent leurs modèles sur les données fournies, mais le classement final se joue sur des données jamais vues. C'est exactement la logique du jeu de test : mesurer la généralisation, pas la mémorisation.

À RETENIR

On évalue un modèle sur des données qu'il n'a jamais vues (jeu de test). La performance sur l'entraînement ne dit rien de la généralisation.

ATTENTION

Ne réglez jamais votre modèle en regardant le jeu de test : il perdrait sa valeur d'évaluation. C'est le rôle du jeu de validation.

× ERREURS FRÉQUENTES

La « fuite de données » (data leakage) : laisser une information du jeu de test influencer l'entraînement (par exemple en normalisant les données avant de les séparer). Le modèle paraît excellent en test, puis échoue en production.

★ ASTUCE

Séparez vos données tout au début du projet, avant toute transformation ou analyse. C'est la protection la plus simple contre les fuites de données.

CONSEILS

- Séparez vos données **AVANT** toute analyse, pour éviter les fuites d'information.
- Sur des données limitées, préférez la validation croisée à une simple division.
- Choisissez des métriques adaptées au déséquilibre des classes.

QUESTIONS DE RÉFLEXION

- Pourquoi ne doit-on jamais régler les choix d'un modèle en observant sa performance sur le jeu de test ?

RÉSUMÉ DU CHAPITRE

- Entraînement pour apprendre, validation pour régler, test pour évaluer.
- La validation croisée fiabilise l'estimation.
- Les bonnes métriques révèlent où le modèle échoue.

MINI-EXERCICE

Pourquoi une précision de 99 % peut-elle être trompeuse pour détecter une maladie rare touchant 1 % de la population ?

Piste : Un modèle qui répond toujours « pas malade » atteint 99 % de précision sans détecter aucun malade. Il faut regarder le rappel (proportion de malades effectivement détectés).

4

CHAPITRE 4

Le sur-apprentissage et comment l'éviter

Le sur-apprentissage est l'ennemi numéro un du praticien. Le reconnaître et le combattre est une compétence clé.


Explication détaillée

Le sur-apprentissage (overfitting) survient quand un modèle colle trop aux données d'entraînement : il en mémorise les détails et le bruit au lieu d'en capturer les tendances générales. Résultat : excellent sur l'entraînement, mauvais sur les données nouvelles. À l'inverse, le sous-apprentissage (underfitting) correspond à un modèle trop simple, incapable de capturer la structure des données.

On repère le sur-apprentissage par un écart important entre la performance d'entraînement (très bonne) et la performance de test (nettement moins bonne). Le bon compromis se situe entre les deux extrêmes : un modèle assez riche pour capturer les tendances, assez sobre pour généraliser.

Plusieurs leviers limitent le sur-apprentissage : disposer de plus de données, simplifier le modèle, utiliser la régularisation (qui pénalise la complexité), et recourir à la validation croisée pour surveiller la généralisation. En Deep Learning, on ajoute des techniques comme le « dropout ».

Comprendre ce compromis, souvent appelé compromis biais-variance, est central : un modèle trop simple a un biais élevé, un modèle trop complexe a une variance élevée. L'art du praticien consiste à trouver l'équilibre.



De gauche à droite : sous-apprentissage, bon ajustement, sur-apprentissage. Le modèle idéal capture la tendance sans épouser le bruit.

► EXEMPLE CONCRET — EDUMENTOR AI

Si un modèle d'EduMentor AI mémorisait par cœur les réponses des apprenants du jeu d'entraînement, il obtiendrait un score parfait à l'entraînement mais échouerait avec de nouveaux apprenants. On préfère un modèle qui capte les tendances générales des difficultés, quitte à être un peu moins « parfait » sur les cas connus.

► EXEMPLE CONCRET

Un modèle de reconnaissance d'images entraîné uniquement sur des photos prises en plein jour peut atteindre une précision remarquable en test... puis échouer totalement sur des photos nocturnes. Ce n'est pas du sur-apprentissage au sens strict, mais un problème voisin : le modèle a appris un contexte trop étroit. La leçon est la même : la performance dépend de la représentativité des données.

À RETENIR

Sur-apprentissage = le modèle mémorise l'entraînement et généralise mal. On le détecte par l'écart entre performance d'entraînement et performance de test.

BONNES PRATIQUES

Face au sur-apprentissage : plus de données, un modèle plus simple, de la régularisation et une validation croisée systématique.

ATTENTION

Un score d'entraînement quasi parfait doit éveiller la méfiance, pas la satisfaction : c'est souvent le symptôme d'un sur-apprentissage.

◆ CONSEIL PROFESSIONNEL

Ne vous réjouissez jamais d'un score d'entraînement parfait : surveillez toujours l'écart avec le score de test. Un praticien expérimenté se méfie d'un modèle « trop bon » sur l'entraînement.

CONSEILS

- Comparez toujours performance d'entraînement et de test : leur écart est votre indicateur de sur-apprentissage.
- Ajoutez de la complexité progressivement, en surveillant la généralisation à chaque étape.

CAS PRATIQUE**Construire un premier classifieur de spam**

Une équipe assemble 5 000 e-mails étiquetés (spam / non-spam), sépare les données en entraînement, validation et test, puis entraîne une régression logistique. Score d'entraînement : 98 %. Score de test : 96 %. L'écart est faible.

Tentées d'améliorer encore, elles passent à un modèle très complexe : score d'entraînement 100 %, score de test 91 %.

Quel modèle faut-il déployer, et pourquoi ?

Analyse : Le premier (régression logistique) : son score de test est meilleur (96 % contre 91 %) et l'écart entraînement-test est faible. Le second modèle, malgré un score d'entraînement parfait, sur-apprend et généralise moins bien. On choisit la généralisation, pas la performance sur l'entraînement.

RÉSUMÉ DU CHAPITRE

- Sur-apprentissage : trop collé aux données ; sous-apprentissage : trop simple.
- On le détecte par l'écart entraînement / test.
- Remèdes : plus de données, simplification, régularisation, validation croisée.


MINI-EXERCICE

Un modèle atteint 99 % à l'entraînement et 62 % au test. Quel est le problème et que proposez-vous ?

Piste : C'est du sur-apprentissage (grand écart). Pistes : simplifier le modèle, ajouter des données, appliquer une régularisation, vérifier par validation croisée.

Résumé visuel

Une vue d'ensemble des idées clés de ce cours, à mémoriser en un coup d'œil.



Le cycle complet d'un projet de Machine Learning, de la donnée à la prédiction.

Quiz d'évaluation

1. En Machine Learning, apprendre revient à...

- A. écrire des règles à la main
- B. minimiser l'erreur entre prédictions et réponses connues
- C. compresser des fichiers
- D. trier une liste

2. Prédire une catégorie (spam / non-spam) relève de...

- A. la régression
- B. la classification
- C. le clustering
- D. le renforcement

3. À quoi sert le jeu de test ?

- A. à entraîner le modèle
- B. à régler les hyperparamètres
- C. à évaluer la généralisation sur des données jamais vues
- D. à stocker les données

4. Le sur-apprentissage se caractérise par...

- A. de mauvais scores partout
- B. un bon score au test seulement
- C. un excellent score à l'entraînement mais un mauvais au test
- D. l'absence de données

5. Quel algorithme classe un point selon la majorité de ses voisins ?

- A. régression linéaire
- B. k plus proches voisins (k-NN)
- C. réseau convolutif
- D. k-means

6. Quelle technique fiabilise l'évaluation sur des données limitées ?

- A. la validation croisée
- B. le sur-apprentissage
- C. l'augmentation du taux d'apprentissage
- D. la suppression du jeu de test

7. Quel algorithme est réputé le plus interprétable ?

- A. forêt aléatoire
- B. arbre de décision unique
- C. réseau de neurones profond
- D. k-means

8. La « fuite de données » (data leakage) se produit quand...

- A. on perd un fichier
- B. une information du test influence l'entraînement
- C. le modèle est trop simple
- D. on manque de données

9. Une ligne de base (baseline) sert à...

- A. compliquer le modèle
- B. disposer d'une référence simple pour juger les gains
- C. supprimer le jeu de test
- D. accélérer le serveur

10. Prédire une note sur 20 est une tâche de...

- A. classification
- B. régression
- C. clustering
- D. renforcement

Corrigé : 1-B · 2-B · 3-C · 4-C · 5-B · 6-A · 7-B · 8-B · 9-B · 10-B

Foire aux questions (FAQ)

Q Faut-il beaucoup de données pour faire du Machine Learning ?

R Cela dépend du problème et de l'algorithme. Les modèles simples peuvent fonctionner avec peu de données ; le Deep Learning en exige généralement beaucoup. Dans tous les cas, la qualité et la représentativité comptent plus que le volume brut.

Q Quel algorithme choisir pour commencer ?

R Commencez toujours par un modèle simple et interprétable (régression linéaire ou logistique, arbre de décision) comme ligne de base, puis complexifiez seulement si nécessaire.

Q Pourquoi mon modèle est-il excellent en test mais mauvais en production ?

R Souvent parce que les données de production diffèrent des données d'entraînement, ou à cause d'une fuite de données pendant l'évaluation. Vérifiez la représentativité de vos données et l'absence de fuite.

Q Classification ou régression : comment trancher ?

R Regardez la nature de la sortie. Une catégorie (oui/non, type A/B/C) appelle une classification ; une valeur numérique continue (prix, durée, note) appelle une régression.

Q Comment savoir si mon modèle sur-apprend ?

R Comparez sa performance sur l'entraînement et sur le test. Un excellent score d'entraînement associé à un score de test nettement plus faible est le signe classique du sur-apprentissage.

Conclusion

Vous disposez maintenant des concepts fondamentaux du Machine Learning : l'idée d'apprendre les règles à partir des données, la distinction entre classification et régression, le rôle crucial des jeux d'entraînement et de test, et le combat permanent contre le sur-apprentissage.

Ces notions ne sont pas théoriques : elles conditionnent la fiabilité de tout système intelligent, y compris les fonctionnalités d'EduMentor AI. Un modèle mal évalué ou en sur-apprentissage donnera de mauvaises recommandations, aussi sophistiqué soit-il.

Le prochain cours prolonge cette base vers le Deep Learning, qui pousse l'apprentissage à un niveau supérieur grâce aux réseaux de neurones, et qui constitue le socle des grands modèles de langage.