

Les grands modèles de langage (LLM)

Comprendre ce qui se cache derrière ChatGPT, Claude ou Gemini : fonctionnement, forces et limites.

NIVEAU

Avancé

DURÉE ESTIMÉE

3 h

CHAPITRES

4

OBJECTIFS PÉDAGOGIQUES

- Expliquer ce qu'est un LLM et comment il génère du texte.
- Comprendre les notions de token, de contexte et d'entraînement.
- Identifier les forces et les limites, dont les hallucinations.
- Savoir comment fiabiliser et spécialiser un LLM pour l'éducation.

Sommaire

1.	Qu'est-ce qu'un grand modèle de langage ?	3
2.	Tokens, contexte et entraînement	6
3.	Forces, limites et hallucinations	9
4.	Spécialiser et fiabiliser un LLM pour l'éducation	12
◆	Résumé visuel	14
Q.	Quiz d'évaluation	15
?	Foire aux questions (FAQ)	17
★	Conclusion	18

1

CHAPITRE 1

Qu'est-ce qu'un grand modèle de langage ?

Les LLM sont au cœur de l'IA générative actuelle. Ce chapitre en donne une définition précise, sans jargon inutile.

Explication détaillée

Un grand modèle de langage (LLM, Large Language Model) est un réseau de neurones profond entraîné sur d'immenses quantités de texte pour prédire la suite d'une séquence de mots. « Grand » renvoie à sa taille : des milliards de paramètres, entraînés sur des corpus de milliers de milliards de mots.

Son principe est étonnamment simple à énoncer : étant donné un début de texte, le modèle prédit le mot (ou fragment de mot) suivant le plus probable, puis recommence, token après token. En répétant ce processus, il produit des phrases, des paragraphes, du code, des explications.

Ce mécanisme de prédiction, appliqué à une échelle massive, produit un résultat qui dépasse la simple complétion : le modèle semble « comprendre » et « raisonner ». Il s'agit en réalité de régularités statistiques apprises sur le langage humain, extrêmement riches, mais qui restent des probabilités.

Les LLM modernes reposent sur l'architecture Transformer, introduite en 2017. Son innovation majeure, le mécanisme d'attention, permet au modèle de pondérer l'importance de chaque mot par rapport aux autres dans une phrase, et de traiter de longues séquences efficacement.

Le modèle prédit le token suivant le plus probable



→ « toit » (p=0.42) · « lit » (p=0.21) · « canapé » (p=0.15)...


Le principe de base d'un LLM : prédire le token suivant le plus probable, de manière répétée.

► EXEMPLE CONCRET — EDMENTOR AI

Quand un apprenant pose une question au chatbot d'EduMentor AI, le LLM ne « cherche » pas une réponse dans une base : il génère mot après mot la suite la plus probable à sa question. C'est puissant, mais cela explique aussi pourquoi, sans garde-fous, il peut inventer une réponse plausible mais fausse.

► **EXEMPLE CONCRET**

La complétion de code dans un éditeur de programmation illustre bien le fonctionnement d'un LLM : à mesure que vous tapez, il propose la suite la plus probable de votre code, apprise sur d'immenses volumes de code existant. Même mécanique que pour le texte : prédire la suite la plus probable, token après token.



Sous le capot d'un LLM : l'architecture Transformer et son mécanisme d'attention.

À RETENIR

Un LLM prédit le token suivant le plus probable, de façon répétée. Cette mécanique simple, à grande échelle, produit du texte cohérent et polyvalent.

ATTENTION

« Sembler comprendre » n'est pas « comprendre ». Un LLM manipule des probabilités sur le langage, pas des faits vérifiés.

★ **ASTUCE**

Pour anticiper le comportement d'un LLM, souvenez-vous qu'il optimise la vraisemblance du texte, pas sa vérité. Cela explique à la fois sa fluidité et ses erreurs assurées.

CONSEILS

- Voyez le LLM comme un moteur de génération de texte probable, pas comme une base de connaissances exacte.
- Pour des faits précis, ne vous fiez jamais à un LLM seul : vérifiez ou ancrez-le sur des sources.

QUESTIONS DE RÉFLEXION

- Si un LLM ne fait que prédire le mot suivant, comment expliquer qu'il semble parfois « raisonner » ? Où se situe la frontière entre régularité statistique et raisonnement ?

RÉSUMÉ DU CHAPITRE

- Un LLM est un réseau profond entraîné à prédire la suite d'un texte.
- Il génère token après token, en s'appuyant sur des régularités statistiques.
- L'architecture Transformer et l'attention en sont le socle.

MINI-EXERCICE

En une phrase, expliquez pourquoi un LLM peut produire une réponse fausse tout en étant grammaticalement parfaite.

Piste : Parce qu'il optimise la probabilité du texte (sa vraisemblance linguistique), pas sa véracité : une phrase fausse peut être très probable statistiquement.

2

CHAPITRE 2

Tokens, contexte et entraînement

Trois notions techniques éclairent le comportement des LLM : le token, la fenêtre de contexte et le processus d'entraînement.

Explication détaillée

Un token est l'unité de texte que le modèle manipule : souvent un mot court, un fragment de mot, ou un signe de ponctuation. Découper le texte en tokens permet au modèle de traiter n'importe quelle langue et n'importe quel vocabulaire, même des mots inconnus, en les décomposant.

La fenêtre de contexte est la quantité de texte que le modèle peut prendre en compte simultanément, mesurée en tokens. Tout ce qui dépasse cette fenêtre est « oublié ». Comprendre cette limite est essentiel : un LLM ne se souvient pas d'une conversation au-delà de son contexte, sauf mécanisme externe.

L'entraînement se déroule en plusieurs phases. D'abord le pré-entraînement, auto-supervisé, où le modèle apprend le langage en prédisant des mots masqués sur d'énormes corpus. Ensuite l'ajustement (fine-tuning) et l'alignement, souvent par apprentissage par renforcement à partir de retours humains, qui rendent le modèle plus utile, plus sûr et mieux aligné sur les attentes.

Ces phases expliquent pourquoi deux modèles de taille comparable peuvent se comporter très différemment : l'alignement et les données d'ajustement façonnent le ton, la prudence et l'utilité du modèle autant que sa taille brute.

« apprentissage » → découpé en tokens

appren

tissage

Un mot inconnu est reconstitué à partir de fragments connus


La tokenisation découpe le texte en unités que le modèle manipule, y compris pour les mots inconnus.

► EXEMPLE CONCRET — EDUMENTOR AI

Dans EduMentor AI, si l'on injecte trop de documents dans le contexte du chatbot, on risque de dépasser sa fenêtre : les premiers documents seront « oubliés ». D'où l'intérêt d'un mécanisme qui sélectionne seulement les passages pertinents avant de les fournir au modèle — c'est le rôle du RAG, vu plus loin.

► EXEMPLE CONCRET

Un long échange avec un assistant illustre la limite de la fenêtre de contexte : après de nombreux messages, l'assistant peut « oublier » une consigne donnée au tout début, simplement parce qu'elle est sortie de sa fenêtre. Ce n'est pas de la négligence, mais une contrainte technique.



La fenêtre de contexte limite ce que le modèle « voit » : au-delà, l'information est oubliée.

À RETENIR

Le token est l'unité de base ; la fenêtre de contexte limite ce que le modèle peut « voir » d'un coup ; l'entraînement combine pré-entraînement, ajustement et alignement.

ATTENTION

Un LLM n'a pas de mémoire persistante : hors de sa fenêtre de contexte, il ne se souvient de rien. Toute continuité doit être gérée par le système autour du modèle.

× ERREURS FRÉQUENTES

Coller des documents entiers dans le contexte « au cas où ». On sature la fenêtre, on augmente le coût et on noie l'information utile, ce qui dégrade la réponse.

◆ CONSEIL PROFESSIONNEL

Fournissez au modèle des extraits ciblés et pertinents plutôt que de longs documents. La pertinence du contexte compte davantage que sa quantité — c'est tout l'intérêt du RAG.

CONSEILS

- Estimez la taille de vos entrées en tokens pour rester dans la fenêtre de contexte.
- Ne surchargez pas le contexte : privilégiez la pertinence à la quantité.

RÉSUMÉ DU CHAPITRE

- Le texte est découpé en tokens.
- La fenêtre de contexte borne ce que le modèle prend en compte.
- L'entraînement passe par pré-entraînement, ajustement et alignement.

MINI-EXERCICE

Pourquoi vaut-il mieux fournir à un LLM trois passages ciblés plutôt qu'un document entier de cent pages ?

Piste : Pour rester dans la fenêtre de contexte, réduire le bruit et le coût, et concentrer le modèle sur l'information pertinente, ce qui améliore la qualité et la fiabilité de la réponse.

Les LLM sont impressionnants mais faillibles. Un usage professionnel exige d'en connaître précisément les limites.

Explication détaillée

Les forces des LLM sont réelles : polyvalence remarquable, qualité de langue, capacité à expliquer, résumer, reformuler, traduire et générer du code. Ils abaissent considérablement la barrière d'accès à de nombreuses tâches intellectuelles.

Leur principale limite est l'hallucination : le modèle produit parfois des affirmations fausses, mais formulées avec assurance et cohérence. Comme il optimise la vraisemblance du texte et non sa véracité, il n'a aucun mécanisme intrinsèque pour distinguer le vrai du plausible.

D'autres limites méritent attention : la sensibilité à la formulation de la question, la reproduction possible de biais présents dans les données d'entraînement, l'absence de connaissance des événements postérieurs à leur entraînement, et une tendance à donner directement la réponse plutôt qu'à guider.

Ces limites ne disqualifient pas les LLM ; elles définissent les conditions d'un usage responsable. En éducation, elles imposent des garde-fous : ancrage documentaire, vérification, transparence, et conception pédagogique évitant la dépendance.

PRINCIPALES LIMITES DES LLM ET LEURS PARADES

Limite	Description	Parade
Hallucination	Réponse fausse mais plausible	Ancrage documentaire (RAG), vérification
Connaissances datées	Ignore l'après-entraînement	RAG sur sources à jour
Biais	Reproduit les biais des données	Vigilance, tests, garde-fous
Sensibilité au prompt	Réponse variable selon la formulation	Ingénierie de prompts
Dépendance	Donne la réponse toute faite	Conception socratique

► EXEMPLE CONCRET — EDUMENTOR AI

Sans garde-fou, si un apprenant demandait au chatbot d'EduMentor AI une date ou une définition précise, le LLM pourrait inventer une réponse crédible mais erronée. La parade adoptée par la plateforme : ancrer les réponses sur des documents de cours vérifiés et citer les sources.

► EXEMPLE CONCRET

Un cas fréquent : demander à un LLM une référence bibliographique précise. Il peut produire un titre, des auteurs et une année parfaitement crédibles... mais totalement inventés. La forme est impeccable, le fond est faux. C'est l'illustration typique de l'hallucination.

À RETENIR

La limite majeure des LLM est l'hallucination : des réponses fausses mais plausibles. Ils optimisent la vraisemblance, pas la vérité.

BONNES PRATIQUES

Pour un usage fiable : ancrer le modèle sur des sources vérifiées, citer ces sources, et faire vérifier les réponses critiques par un humain.

ATTENTION

Les biais présents dans les données d'entraînement peuvent se retrouver dans les réponses. La vigilance est indispensable, surtout sur des sujets sensibles.

× ERREURS FRÉQUENTES

Prendre une réponse fluide et assurée pour une réponse exacte. La confiance apparente d'un LLM n'a aucun rapport avec la véracité de ce qu'il affirme.

CONSEILS

- Ne demandez jamais un fait critique à un LLM sans possibilité de vérification.
- Reformulez une question si la réponse semble incertaine : les LLM y sont sensibles.

CAS PRATIQUE**Pourquoi le chatbot a-t-il inventé une citation ?**

Un apprenant demande à un assistant non ancré : « Cite-moi une étude qui prouve l'efficacité de cette méthode. » L'assistant répond avec une référence détaillée et convaincante. Vérification faite, l'étude n'existe pas.

L'apprenant est surpris : la réponse semblait irréfutable.

Qu'est-ce qui explique ce comportement, et comment l'éviter ?

Analyse : Le modèle a généré la suite de texte la plus probable à une demande de citation, sans accès à une base réelle : il a « halluciné » une référence plausible. Pour l'éviter, il faut ancrer le modèle sur une base documentaire vérifiée (RAG) et lui demander de ne citer que des sources réellement fournies, ou de signaler l'absence d'information.

RÉSUMÉ DU CHAPITRE

- Forces : polyvalence, qualité de langue, explication, génération.
- Limite majeure : les hallucinations.
- Autres limites : biais, sensibilité au prompt, connaissances datées.

MINI-EXERCICE

Un apprenant reçoit du chatbot une définition qui « sonne juste ». Quel réflexe adopter avant de la considérer comme vraie ?

Piste : Vérifier la définition contre une source fiable (document de cours, référence citée). Une réponse fluide n'est pas une garantie d'exactitude.

4

CHAPITRE 4

Spécialiser et fiabiliser un LLM pour l'éducation

Un LLM générique n'est pas un tuteur. Ce chapitre présente les leviers pour l'adapter et le fiabiliser dans un contexte pédagogique.

Explication détaillée

Le premier levier est l'ingénierie de prompts : formuler des instructions claires qui précisent le rôle (« tu es un tuteur bienveillant »), le contexte (le niveau de l'apprenant), la tâche et le format attendu. Bien conçue, elle oriente fortement le comportement du modèle sans le réentraîner.

Le deuxième levier est l'ancrage documentaire (RAG) : fournir au modèle, au moment de répondre, des passages pertinents extraits d'une base de documents vérifiés, et lui demander de s'appuyer dessus en citant ses sources. C'est le moyen le plus efficace de réduire les hallucinations.

Le troisième levier est le fine-tuning : réentraîner un modèle pré-existant sur des données spécifiques pour l'adapter à un domaine ou à un style. Plus coûteux, il est réservé aux cas où le prompt et le RAG ne suffisent pas.

Enfin, la conception pédagogique elle-même compte : demander au modèle de guider plutôt que de donner la réponse, d'adapter son explication au niveau, et d'afficher ses sources. La fiabilité d'un tuteur IA tient autant à sa conception qu'à la puissance brute du modèle.

► EXEMPLE CONCRET — EDUMENTOR AI

EduMentor AI combine ces leviers : un prompt qui injecte le niveau de l'apprenant et une consigne socratique, un RAG qui ancre les réponses sur les supports de cours et cite le PDF et la page, et une conception qui privilégie le guidage. Le LLM générique devient ainsi un tuteur spécialisé et fiable.

► EXEMPLE CONCRET

Un assistant juridique d'entreprise illustre la spécialisation par RAG : plutôt que de se fier à la mémoire d'un LLM générique, il récupère les clauses pertinentes dans les contrats internes de l'entreprise, puis génère une réponse ancrée et citée. Le même modèle générique devient un expert fiable d'un domaine précis.

À RETENIR

Trois leviers pour adapter un LLM : l'ingénierie de prompts, l'ancrage documentaire (RAG) et le fine-tuning. En éducation, la conception pédagogique est un quatrième levier essentiel.

BONNES PRATIQUES

Commencez par le prompt et le RAG (rapides, peu coûteux) avant d'envisager un fine-tuning. Injectez toujours le niveau de l'apprenant dans le prompt.

◆ CONSEIL PROFESSIONNEL

Adoptez l'ordre coût/efficacité : d'abord l'ingénierie de prompts, puis le RAG, et seulement en dernier recours le fine-tuning. On atteint souvent l'objectif sans réentraîner le modèle.

CONSEILS

- Structurez vos prompts avec rôle, contexte, tâche et format : c'est le sujet du cours sur le Prompt Engineering.
- Faites citer les sources par le modèle : cela renforce la confiance et la vérifiabilité.

QUESTIONS DE RÉFLEXION

- Pourquoi l'ancrage documentaire (RAG) est-il souvent préférable au fine-tuning pour maintenir un assistant à jour ?

RÉSUMÉ DU CHAPITRE

- L'ingénierie de prompts oriente le comportement du modèle.
- Le RAG l'ancre sur des sources vérifiées et réduit les hallucinations.
- Le fine-tuning le spécialise, à un coût plus élevé.

MINI-EXERCICE

Classez du moins au plus coûteux : fine-tuning, ingénierie de prompts, ancrage documentaire (RAG).

Piste : Du moins au plus coûteux : ingénierie de prompts, puis RAG, puis fine-tuning.

Résumé visuel

Une vue d'ensemble des idées clés de ce cours, à mémoriser en un coup d'œil.

Le modèle prédit le token suivant le plus probable



→ « toit » (p=0.42) · « lit » (p=0.21) · « canapé » (p=0.15)...

L'idée centrale d'un LLM tient en une image : prédire le token suivant le plus probable.

Quiz d'évaluation

1. Comment un LLM génère-t-il du texte ?

- A. en copiant une page web
- B. en prédisant le token suivant le plus probable, de façon répétée
- C. en tirant des lettres au hasard
- D. en traduisant depuis l'anglais

2. Un « token » est...

- A. un mot de passe
- B. une unité de texte (mot ou fragment de mot)
- C. un type de fichier
- D. une carte graphique

3. La « fenêtre de contexte » désigne...

- A. la taille de l'écran
- B. la quantité de texte prise en compte simultanément
- C. la vitesse du modèle
- D. le nombre de paramètres

4. Une hallucination est...

- A. un bug d'affichage
- B. une information fausse mais présentée comme plausible
- C. une panne réseau
- D. un ralentissement

5. Quel levier réduit le plus directement les hallucinations ?

- A. augmenter la température
- B. l'ancrage documentaire (RAG)
- C. réduire la fenêtre de contexte
- D. changer la police

6. Quelle architecture est à la base des LLM modernes ?

- A. le CNN
- B. le RNN classique
- C. le Transformer
- D. l'arbre de décision

7. Qu'est-ce qu'une hallucination d'un LLM ?

- A. un bug d'affichage
- B. une information fausse mais plausible
- C. une panne réseau
- D. un ralentissement

8. La fenêtre de contexte détermine...

- A. la taille de l'écran
- B. la quantité de texte prise en compte simultanément
- C. le nombre de paramètres
- D. la vitesse du modèle

9. Classez du moins au plus coûteux : fine-tuning, prompt, RAG.

- A. fine-tuning < RAG < prompt
- B. prompt < RAG < fine-tuning
- C. RAG < prompt < fine-tuning
- D. prompt < fine-tuning < RAG

10. Une référence bibliographique inventée par un LLM est un exemple de...

- A. fine-tuning
- B. hallucination
- C. tokenisation
- D. attention

Corrigé : 1-B · 2-B · 3-B · 4-B · 5-B · 6-C · 7-B · 8-B · 9-B · 10-B

Foire aux questions (FAQ)

Q Un LLM dit-il la vérité ?

R Pas nécessairement. Il produit le texte le plus probable, pas le plus vrai. Il peut donc énoncer des faussetés avec assurance (hallucinations). Pour des faits, il faut l'ancrer sur des sources et vérifier.

Q Pourquoi la même question donne-t-elle parfois des réponses différentes ?

R Parce que la génération comporte une part d'aléa et que le modèle est sensible à la formulation. Reformuler ou préciser la demande améliore souvent la réponse.

Q Un LLM connaît-il l'actualité ?

R Seulement jusqu'à sa date d'entraînement. Pour des informations récentes, il faut le connecter à des sources à jour, par exemple via un mécanisme de récupération (RAG).

Q Qu'est-ce qu'un token, concrètement ?

R Une unité de texte manipulée par le modèle : souvent un mot court ou un fragment de mot. Découper en tokens permet de traiter n'importe quelle langue et même des mots inconnus.

Q Faut-il réentraîner un LLM pour l'adapter à mon domaine ?

R Rarement en premier recours. L'ingénierie de prompts et l'ancrage documentaire (RAG) suffisent souvent, pour un coût bien moindre que le fine-tuning.

Conclusion

Vous comprenez maintenant ce qu'est un grand modèle de langage : un réseau profond qui prédit le token suivant, à très grande échelle, avec une puissance remarquable et des limites bien réelles, au premier rang desquelles les hallucinations.

Surtout, vous savez qu'un LLM générique n'est pas un tuteur : il faut l'encadrer par l'ingénierie de prompts, l'ancrer sur des sources fiables (RAG) et le concevoir pour faire apprendre. C'est exactement la démarche d'EduMentor AI.

Les deux prochains cours approfondissent ces deux leviers décisifs : le Prompt Engineering, puis le RAG, qui transforment un modèle générique en assistant pédagogique fiable.