

# Le RAG (Retrieval-Augmented Generation)

Ancrer un modèle de langage sur des sources fiables pour générer des réponses vérifiables, à jour et sans hallucination.

NIVEAU

**Avancé**

DURÉE ESTIMÉE

**3 h 30**

CHAPITRES

**4**

## OBJECTIFS PÉDAGOGIQUES

- Comprendre pourquoi le RAG répond aux limites des LLM.
- Décrire les étapes d'un pipeline RAG, de l'indexation à la génération.
- Comprendre les embeddings, la base vectorielle et la recherche sémantique.
- Concevoir un RAG pédagogique qui cite ses sources et reste fiable.

# Sommaire

---

|    |                                                            |    |
|----|------------------------------------------------------------|----|
| 1. | Pourquoi le RAG : répondre aux limites des LLM.....        | 3  |
| 2. | Les étapes d'un pipeline RAG.....                          | 5  |
| 3. | Embeddings, base vectorielle et recherche sémantique ..... | 7  |
| 4. | Concevoir un RAG pédagogique fiable .....                  | 10 |
| ◆  | Résumé visuel .....                                        | 13 |
| Q. | Quiz d'évaluation .....                                    | 14 |
| ?  | Foire aux questions (FAQ).....                             | 16 |
| ★  | Conclusion .....                                           | 17 |

## 1

## CHAPITRE 1

# Pourquoi le RAG : répondre aux limites des LLM

Le RAG n'est pas un gadget : c'est la réponse la plus directe aux deux plus grands défauts des LLM, l'hallucination et les connaissances datées.


## Explication détaillée

Un LLM répond à partir de ce qu'il a appris pendant son entraînement. Deux problèmes en découlent : il peut inventer des réponses plausibles mais fausses (hallucinations), et il ignore tout ce qui est postérieur à son entraînement ou spécifique à un contexte particulier (vos documents, votre cours).

Le RAG (Retrieval-Augmented Generation, génération augmentée par récupération) résout ces problèmes en ajoutant une étape avant la génération : on récupère d'abord, dans une base de documents fiables, les passages pertinents pour la question, puis on les fournit au modèle en lui demandant de s'appuyer dessus pour répondre.

Le modèle ne répond donc plus « de mémoire », mais à partir d'un contexte documentaire vérifié et à jour. Résultat : les hallucinations diminuent fortement, les réponses reflètent des sources précises, et l'on peut même citer ces sources pour permettre la vérification.

Le RAG offre un autre avantage pratique majeur : pour mettre à jour les connaissances du système, il suffit de mettre à jour la base de documents, sans réentraîner le modèle. C'est souple, rapide et économique.



*Le pipeline RAG : la question déclenche une recherche documentaire, dont les résultats nourrissent la génération de la réponse.*

### ► EXEMPLE CONCRET — EDUMENTOR AI

Sans RAG, le chatbot d'EduMentor AI pourrait inventer une définition. Avec RAG, il reçoit d'abord les passages exacts du cours concerné, génère sa réponse à partir d'eux, et indique la source (PDF et numéro de page). L'apprenant obtient une réponse fiable et vérifiable.

### ► EXEMPLE CONCRET

Hors éducation, une entreprise dont la documentation interne évolue chaque semaine ne peut pas réentraîner un modèle à chaque mise à jour. Avec un RAG, il lui suffit d'actualiser sa base documentaire : l'assistant répond toujours à partir de la dernière version, en citant le document source. C'est souple, économique et fiable.

**À RETENIR**

Le RAG récupère des passages fiables avant de générer, ce qui réduit fortement les hallucinations et permet des réponses à jour et vérifiables.

**BONNES PRATIQUES**

Pour mettre à jour les connaissances d'un système RAG, mettez à jour la base documentaire : inutile de réentraîner le modèle.

**★ ASTUCE**

Voyez le RAG comme « un examen à livre ouvert » pour le modèle : au lieu de répondre de mémoire, il consulte les bonnes pages avant de répondre.

**CONSEILS**

- Privilégiez le RAG dès que l'exactitude et la traçabilité des réponses sont importantes.
- Constituez une base documentaire de qualité : le RAG ne vaut que ce que valent ses sources.

**QUESTIONS DE RÉFLEXION**

- Pourquoi mettre à jour une base documentaire est-il bien plus simple et moins risqué que de réentraîner un modèle ?

**RÉSUMÉ DU CHAPITRE**

- Les LLM hallucinent et ont des connaissances datées.
- Le RAG ancre la réponse sur des documents récupérés au moment de la question.
- Il réduit les hallucinations et permet de citer les sources.

**MINI-EXERCICE**

Un LLM seul et un système RAG reçoivent la question : « Que dit le chapitre 3 de notre cours sur les fractions ? » Lequel peut répondre correctement, et pourquoi ?

**Piste :** Le système RAG : il peut récupérer le chapitre 3 dans la base documentaire et s'appuyer dessus. Le LLM seul n'a jamais vu ce cours et inventerait ou refuserait de répondre.

## 2

## CHAPITRE 2

## Les étapes d'un pipeline RAG

Un RAG se décompose en deux grandes phases : préparer la base (indexation) et répondre (récupération puis génération).

### Explication détaillée

La phase d'indexation prépare les documents une fois pour toutes. On collecte les documents (PDF de cours, articles), on en extrait le texte, puis on le découpe en fragments de taille raisonnable, appelés chunks. Chaque chunk est ensuite transformé en vecteur numérique (embedding) et stocké dans une base vectorielle.

La phase de récupération intervient à chaque question. La question de l'apprenant est elle aussi transformée en vecteur, puis comparée aux vecteurs des chunks pour trouver les passages sémantiquement les plus proches. On récupère ainsi les quelques fragments les plus pertinents.

La phase de génération assemble le tout : on construit un prompt contenant la question et les passages récupérés, en demandant au modèle de répondre en s'appuyant sur ces passages et de citer ses sources. Le LLM génère alors une réponse ancrée.

Le découpage (chunking) mérite une attention particulière : des chunks trop grands diluent la pertinence et saturent le contexte ; trop petits, ils perdent le sens. La taille des fragments et leur chevauchement se règlent selon le type de document.

#### ► EXEMPLE CONCRET — EDUMENTOR AI

Dans EduMentor AI, les huit supports de cours sont indexés : chaque PDF est découpé en passages, transformés en embeddings et stockés. Quand un apprenant pose une question, la plateforme récupère les 3 ou 4 passages les plus pertinents, les fournit au LLM, et affiche la réponse avec la référence du support et de la page.

#### ► EXEMPLE CONCRET

Un assistant de support technique illustre le pipeline : à la question « comment réinitialiser l'appareil ? », le système découpe au préalable les manuels en passages, retrouve le passage exact sur la réinitialisation, puis génère une réponse pas à pas fondée sur ce passage. Sans indexation préalable, rien de tout cela ne serait possible.

### À RETENIR

Indexation : collecte → extraction → découpage en chunks → embeddings → base vectorielle. Réponse : question → récupération des chunks pertinents → génération ancrée.

**ATTENTION**

La qualité du découpage conditionne tout : des chunks mal dimensionnés dégradent la pertinence de la récupération, donc la qualité des réponses.

**× ERREURS FRÉQUENTES**

Négliger le nettoyage du texte avant l'indexation. En-têtes, pieds de page, numéros et artefacts d'extraction polluent les passages et dégradent la pertinence de la recherche.

**◆ CONSEIL PROFESSIONNEL**

Documentez les paramètres de votre découpage (taille des chunks, chevauchement) : ils ont un impact majeur et devront être ajustés en fonction des résultats observés.

**CONSEILS**

- Commencez avec des chunks de taille moyenne et un léger chevauchement, puis ajustez selon les résultats.
- Nettoyez le texte extrait des PDF (en-têtes, pieds de page) avant l'indexation.

**RÉSUMÉ DU CHAPITRE**

- Deux phases : indexation (préparer) et réponse (récupérer puis générer).
- Le texte est découpé en chunks, vectorisés et stockés.
- La question déclenche une recherche sémantique puis une génération ancrée.

**MINI-EXERCICE**

Dans quel ordre interviennent ces étapes lors d'une question : génération, récupération, vectorisation de la question ?

**Piste :** 1) Vectorisation de la question, 2) récupération des passages pertinents, 3) génération de la réponse à partir de ces passages.

**EXERCICE**

**INTERMÉDIAIRE** Remettez ces étapes dans l'ordre : génération, découpage en chunks, vectorisation de la question, recherche, extraction du texte des PDF.

**Piste :** Indexation (une fois) : extraction du texte des PDF → découpage en chunks → (vectorisation et stockage).  
Réponse (à chaque question) : vectorisation de la question → recherche → génération.

## 3

## CHAPITRE 3

## Embeddings, base vectorielle et recherche sémantique

Le cœur technique du RAG tient en trois notions liées. Les comprendre, c'est comprendre pourquoi le RAG « trouve » les bons passages.


### Explication détaillée

Un embedding est une représentation vectorielle du sens d'un texte : une liste de nombres qui situe le texte dans un espace mathématique. La propriété clé est que deux textes de sens proche ont des vecteurs proches. « Voiture » et « automobile » seront voisins ; « voiture » et « banane », éloignés.

La base vectorielle stocke ces embeddings et permet de retrouver très rapidement les vecteurs les plus proches d'un vecteur donné. C'est ce qui rend la recherche efficace même sur de grands volumes. Des outils comme les bases vectorielles dédiées sont conçus exactement pour cela.

La recherche sémantique découle de ces deux briques : plutôt que de chercher des mots identiques (recherche par mots-clés), on cherche des sens proches. Une question formulée avec des mots différents de ceux du cours retrouvera quand même le bon passage, parce que le sens, lui, est proche.

C'est la grande supériorité du RAG sur une simple recherche textuelle : il comprend l'intention, pas seulement les mots. Un apprenant qui demande « comment la machine apprend toute seule ? » retrouvera le passage sur l'apprentissage automatique, même sans employer ce terme exact.



Les mots de sens proche sont voisins dans l'espace vectoriel

*Dans l'espace des embeddings, les textes de sens proche sont voisins : c'est ce qui rend la recherche sémantique possible.*

### RECHERCHE PAR MOTS-CLÉS ET RECHERCHE SÉMANTIQUE

| Critère              | Mots-clés                     | Sémantique (embeddings)             |
|----------------------|-------------------------------|-------------------------------------|
| <b>Principe</b>      | Correspondance exacte de mots | Proximité de sens                   |
| <b>Reformulation</b> | Échoue si mots différents     | Retrouve malgré des mots différents |
| <b>Synonymes</b>     | Ignorés                       | Pris en compte                      |
| <b>Exemple</b>       | « voiture » ≠ « automobile »  | « voiture » ≈ « automobile »        |

#### ► EXEMPLE CONCRET — EDUMENTOR AI

Si un apprenant d'EduMentor AI tape « c'est quoi quand l'IA invente des trucs faux ? », la recherche sémantique retrouvera le passage sur les hallucinations des LLM, bien que le mot « hallucination » n'apparaisse pas dans sa question. Les vecteurs de sens sont proches.

#### ► EXEMPLE CONCRET

Un moteur de recherche juridique illustre l'intérêt du sémantique : une requête « rupture de contrat sans préavis » doit retrouver des passages parlant de « résiliation anticipée », même sans les mots exacts. La recherche par mots-clés échouerait ; la recherche sémantique réussit, car les sens sont proches.

### À RETENIR

Embedding = vecteur de sens ; base vectorielle = stockage et recherche rapide de vecteurs ; recherche sémantique = trouver par le sens, pas par les mots exacts.

### BONNES PRATIQUES

Choisissez un modèle d'embeddings adapté à votre langue (ici le français) : la qualité de la recherche en dépend directement.

#### ★ ASTUCE

Testez votre RAG avec des questions volontairement formulées autrement que le cours. C'est le meilleur moyen de vérifier que la recherche fonctionne par le sens, pas par les mots.

### CONSEILS

- Testez la recherche avec des questions formulées différemment du cours : c'est le meilleur test de la recherche sémantique.
- Surveillez la pertinence des passages récupérés : c'est là que se joue la qualité finale.



### RÉSUMÉ DU CHAPITRE

- L'embedding encode le sens sous forme de vecteur.
- La base vectorielle permet une recherche rapide par proximité.
- La recherche sémantique trouve par le sens, pas par les mots.

### MINI-EXERCICE

Pourquoi la recherche sémantique retrouve-t-elle un passage pertinent même si la question n'emploie aucun mot du texte original ?

---

**Piste :** Parce qu'elle compare des embeddings (vecteurs de sens) : si le sens de la question est proche de celui du passage, leurs vecteurs sont proches, indépendamment des mots exacts utilisés.

## 4

## CHAPITRE 4

## Concevoir un RAG pédagogique fiable

Un RAG technique ne suffit pas : en éducation, il doit être conçu pour la fiabilité, la transparence et l'adaptation.

### Explication détaillée

La fiabilité impose des garde-fous. On demande au modèle de s'appuyer strictement sur les passages récupérés et de répondre « je ne trouve pas cette information dans le cours » plutôt que d'inventer lorsqu'aucun passage pertinent n'est trouvé. Ce comportement, piloté par le prompt, est décisif.

La transparence passe par la citation des sources : afficher, pour chaque réponse, le document et la page d'où provient l'information. L'apprenant peut ainsi vérifier, et l'enseignant faire confiance au système. C'est un pilier de l'IA responsable en éducation.

L'adaptation combine RAG et prompt engineering : une fois les passages récupérés, on demande au modèle de reformuler l'explication au niveau de l'apprenant. Les mêmes sources donnent ainsi une réponse plus simple à un débutant, plus approfondie à un avancé.

Enfin, l'évaluation compte : il faut vérifier régulièrement que les passages récupérés sont pertinents et que les réponses sont fidèles aux sources. Un RAG se surveille et s'améliore dans le temps, notamment en enrichissant et en nettoyant la base documentaire.

#### ► EXEMPLE CONCRET — EDUMENTOR AI

EduMentor AI applique ces principes : le chatbot répond à partir des supports de cours, cite le PDF et la page, signale quand une information n'y figure pas, et adapte le niveau de l'explication. Le RAG transforme ainsi un LLM générique en tuteur fiable et vérifiable.

#### ► EXEMPLE CONCRET

Un assistant médical documentaire montre l'enjeu de fiabilité : il ne doit répondre qu'à partir de protocoles validés, citer la source précise, et refuser d'inventer en l'absence d'information. Les mêmes exigences — ancrage strict, citation, refus de combler les vides — s'appliquent à tout RAG sérieux, éducatif comme professionnel.

### À RETENIR

Un RAG pédagogique fiable : s'appuie strictement sur les sources, signale l'absence d'information, cite ses sources et adapte le niveau.

**BONNES PRATIQUES**

Affichez toujours les sources (document + page) : c'est ce qui distingue un tuteur fiable d'un simple générateur de texte.

**ATTENTION**

Le RAG réduit les hallucinations mais ne les élimine pas totalement : un passage mal récupéré ou mal interprété reste possible. La vérification demeure utile.

**× ERREURS FRÉQUENTES**

Croire que le RAG élimine totalement les hallucinations. Il les réduit fortement, mais un passage mal récupéré ou mal interprété reste possible : la vérification garde son utilité.

**◆ CONSEIL PROFESSIONNEL**

Faites toujours citer la source exacte (document + page) par le système. La citation n'est pas un détail cosmétique : c'est ce qui rend la réponse vérifiable et digne de confiance.

**CONSEILS**

- Imposez au modèle de citer explicitement le passage utilisé : cela améliore la fidélité aux sources.
- Enrichissez et nettoyez régulièrement la base documentaire : c'est le principal levier d'amélioration.

**CAS PRATIQUE****Un RAG sur la documentation d'une entreprise**

Une société déploie un assistant interne fondé sur un RAG au-dessus de ses procédures. Un employé demande une règle qui a été supprimée le mois précédent.

L'assistant, correctement conçu, ne trouve aucun passage pertinent à jour et le signale, au lieu d'inventer une règle plausible.

**En quoi ce comportement illustre-t-il un RAG bien conçu ?**

**Analyse** : Un RAG fiable s'appuie strictement sur les documents disponibles et signale l'absence d'information plutôt que de fabriquer une réponse. La mise à jour de la base (suppression de la règle obsolète) se répercute immédiatement, sans réentraînement, et la transparence (dire « je ne trouve pas ») protège l'utilisateur d'une erreur.

### RÉSUMÉ DU CHAPITRE

- Garde-fous : s'appuyer sur les sources, signaler l'absence d'information.
- Transparence : citer document et page.
- Adaptation au niveau et évaluation continue.

### MINI-EXERCICE

Un apprenant pose une question dont la réponse n'est dans aucun support. Comment un RAG pédagogique bien conçu doit-il réagir ?


---

**Piste :** Il doit indiquer que l'information ne figure pas dans les supports de cours, plutôt que d'inventer une réponse. Il peut éventuellement proposer une piste ou renvoyer vers une ressource, mais sans fabriquer de contenu.

## Résumé visuel

---

Une vue d'ensemble des idées clés de ce cours, à mémoriser en un coup d'œil.



*Le pipeline RAG : récupérer des passages fiables, puis générer une réponse ancrée et citée.*

# Quiz d'évaluation

---

## 1. Que signifie RAG ?

- A. Random Access Generation
- B. Retrieval-Augmented Generation
- C. Rapid AI Growth
- D. Recursive Automatic Grouping

## 2. Le RAG aide surtout à réduire...

- A. la vitesse d'affichage
- B. les hallucinations et les informations obsolètes
- C. la taille de l'écran
- D. le nombre d'utilisateurs

## 3. Un embedding est...

- A. une image
- B. une représentation vectorielle du sens d'un texte
- C. un mot de passe
- D. un fichier audio

## 4. Où stocke-t-on les embeddings pour une recherche rapide ?

- A. dans un tableur
- B. dans une base de données vectorielle
- C. dans une image
- D. dans la mémoire vive uniquement

## 5. Pourquoi découpe-t-on les documents en chunks ?

- A. pour les supprimer
- B. pour récupérer des passages pertinents de taille gérable
- C. pour les traduire
- D. pour les imprimer

## 6. Quel comportement rend un RAG pédagogique fiable ?

- A. inventer quand il ne sait pas
- B. s'appuyer sur les sources et signaler l'absence d'information
- C. masquer les sources
- D. répondre toujours plus longuement

**7. Le RAG revient à donner au modèle...**

- A. un examen à livre fermé
- B. un examen à livre ouvert (consultation de sources)
- C. plus de paramètres
- D. une fenêtre plus petite

**8. La recherche sémantique retrouve un passage même sans les mots exacts parce qu'elle compare...**

- A. des mots-clés
- B. des embeddings (vecteurs de sens)
- C. des dates
- D. des couleurs

**9. Pour mettre à jour les connaissances d'un RAG, il faut...**

- A. réentraîner le modèle
- B. mettre à jour la base documentaire
- C. changer de langue
- D. réduire les chunks à un mot

**10. Un RAG bien conçu, face à une information absente des sources,...**

- A. invente une réponse plausible
- B. signale qu'il ne trouve pas l'information
- C. répond au hasard
- D. cite une source fausse

**Corrigé :** 1-B · 2-B · 3-B · 4-B · 5-B · 6-B · 7-B · 8-B · 9-B · 10-B

## Foire aux questions (FAQ)

---

**Q Le RAG remplace-t-il le fine-tuning ?**

**R** Ils répondent à des besoins différents. Le RAG apporte des connaissances à jour et vérifiables sans réentraînement ; le fine-tuning ajuste le comportement ou le style du modèle. On les combine parfois, mais le RAG suffit souvent.

**Q Le RAG supprime-t-il totalement les hallucinations ?**

**R** Non, il les réduit fortement. Un passage mal récupéré ou mal interprété peut encore produire une erreur. C'est pourquoi la citation des sources et la vérification restent importantes.

**Q Quelle taille de chunk choisir ?**

**R** Il n'y a pas de valeur universelle. On commence souvent par des passages de taille moyenne avec un léger chevauchement, puis on ajuste selon la pertinence observée et le type de document.

**Q Qu'est-ce qu'une base vectorielle ?**

**R** Une base de données conçue pour stocker des embeddings et retrouver très rapidement les vecteurs les plus proches d'une requête. C'est elle qui rend la recherche sémantique efficace à grande échelle.

**Q Pourquoi la recherche sémantique est-elle supérieure aux mots-clés ?**

**R** Parce qu'elle compare le sens et non les mots exacts : elle retrouve l'information même si la question emploie des synonymes ou une formulation différente de celle du document.



## Conclusion

---

Le RAG est sans doute la brique la plus importante pour une IA éducative fiable. Vous comprenez désormais pourquoi il répond aux limites des LLM, comment fonctionne son pipeline, et ce que recouvrent les embeddings, la base vectorielle et la recherche sémantique.

Surtout, vous savez qu'un RAG pédagogique ne se limite pas à la technique : il doit s'appuyer strictement sur ses sources, citer document et page, signaler l'absence d'information et adapter le niveau. C'est exactement la démarche d'EduMentor AI.

Le cours suivant réunit tout ce que vous avez appris dans une interface concrète : le chatbot pédagogique, qui met le LLM, le prompt engineering et le RAG au service d'un dialogue utile avec l'apprenant.